

---

```
title: "Análisis exploratorio de datos (EDA)" subtitle: "Home Credit Default Risk" author:
```

- name: "Gerardo Guerrero"
  - name: "Juan Pablo Cordero"
  - name: "Jerónimo Deli"
  - name: "Romain S" date: "2025-12-09" format: html: theme: default toc: false code-fold: true number-sections: true execute: echo: true warning: false error: false jupyter: python3 editor: visual
- 

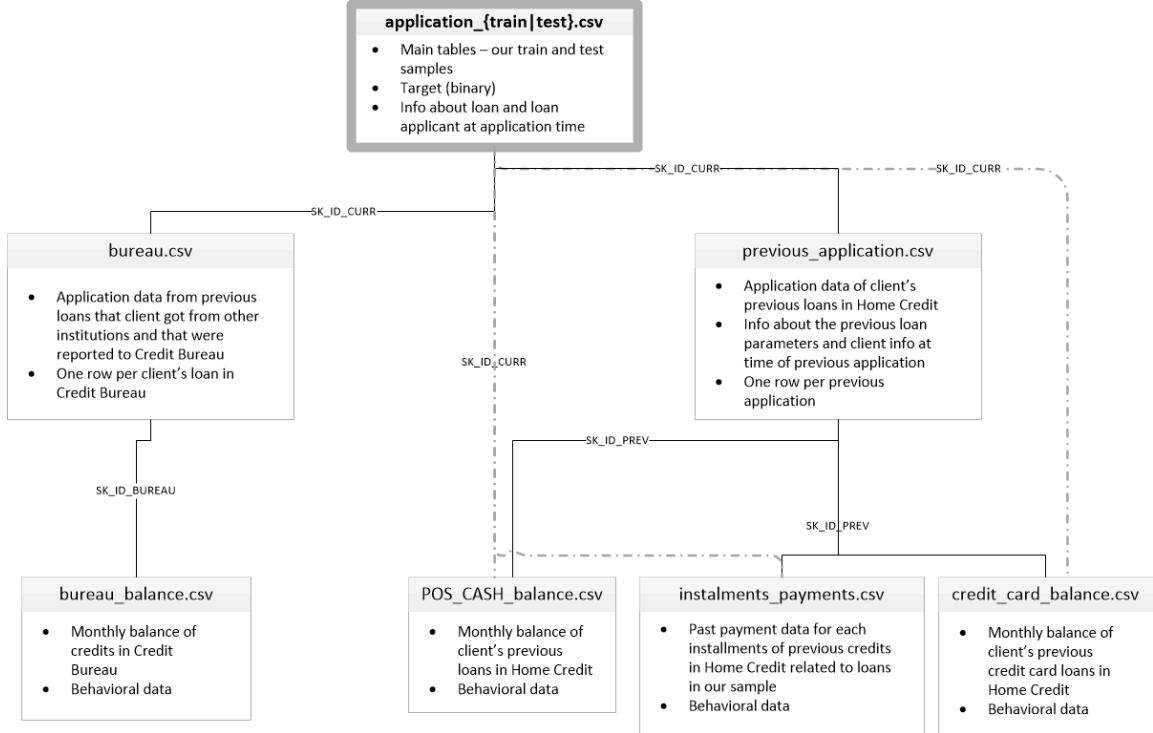
```
In [ ]: #| echo: false
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import math
from IPython.display import Markdown

#display all columns
pd.set_option('display.max_columns', None)
```

```
In [2]: #| echo: false
applications = pd.read_csv('../data/home-credit-default-risk/application_
applications.columns = applications.columns.str.lower()
applications.Name = 'applications'
```

## Introducción

En este cuaderno, realizaremos un análisis exploratorio de datos (EDA) en el conjunto de datos "Home Credit Default Risk" de [Home Credit Group](#). El objetivo es comprender mejor las características de los datos previo al desarrollo de modelos predictivos.



```
In [3]: display(applications.target.value_counts(normalize=True).to_frame().reset_ir
```

	0	1
<b>proportion</b>	0.919271	0.080729

Estamos ante un caso de clasificación binaria, donde el objetivo es predecir si un cliente incumplirá con el pago de un préstamo. La variable objetivo es `TARGET`, que toma el valor 1 si el cliente incumple y 0 en caso contrario.

Esto representa un caso de desbalanceo de clases, ya que la mayoría de los clientes no incumplen con sus pagos. Sin embargo, es crucial identificar a aquellos que sí lo harán para mitigar riesgos financieros.

En ese sentido, buscaremos obtener un modelo que optimice PR-AUC (Precision-Recall Area Under Curve), ya que nos interesa maximizar el recall minimizando los falsos positivos.

## Applications

Para evitar el data snooping bias, realizamos la división del conjunto de datos en train y test antes de realizar el análisis exploratorio de datos.

Además es importante que esta división se realice de manera estratificada por la variable objetivo, para asegurar que ambas particiones mantengan la misma proporción de clases.

```
In [4]: from sklearn.model_selection import train_test_split

X = applications.drop(columns=['target']) # Variables predictoras
y = applications['target'] # Variable objetivo

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

app = pd.concat([X_train, y_train], axis=1)
app.Name = 'applications_train'
```

```
In [5]: def calculate_correlation_between_features(df, features, top_k=20):
    corr_matrix = df[features].corr().abs()

    # Máscara para quedarte solo con la mitad superior
    mask = np.tril(np.ones_like(corr_matrix, dtype=bool), k=0)
    corr_tri = corr_matrix.mask(mask)

    plt.figure(figsize=(10, 8))
    im = plt.imshow(corr_tri, cmap='coolwarm', vmin=0, vmax=1)
    plt.colorbar(im, label='Correlación absoluta')

    plt.xticks(ticks=np.arange(len(features)), labels=features, rotation=90)
    plt.yticks(ticks=np.arange(len(features)), labels=features)

    plt.title('Matriz de correlación')
    plt.tight_layout()
    plt.show()

    # Obtener solo la mitad superior para evitar duplicados y diagonal
    pairs = []
    n = len(features)
    for i in range(n):
        for j in range(i+1, n):
            pairs.append((
                features[i],
                features[j],
                corr_matrix.iloc[i, j]
            ))

    # Ordenar por correlación de mayor a menor
    pairs_sorted = sorted(pairs, key=lambda x: x[2], reverse=True)[:top_k]

    # Preparar datos para graficar
    pair_labels = [f'{a} - {b}' for a, b, _ in pairs_sorted]
    corr_values = [c for _, _, c in pairs_sorted]

    fig, ax = plt.subplots(figsize=(8, 0.4 * top_k + 1))

    # "Heatmap" vertical de una sola columna
    im = ax.imshow(
        np.array(corr_values)[..., None], # shape (top_k, 1)
        cmap='coolwarm',
        vmin=0,
```

```

        vmax=1,
        aspect='auto'
    )

# Etiquetas en el eje y: los pares
ax.set_yticks(np.arange(top_k))
ax.set_yticklabels(pair_labels)
ax.set_xticks([0])
ax.set_xticklabels(["Correlación"])

# Poner el valor de corr y el nombre del par dentro de la celda (si quiere)
for i, (label, val) in enumerate(zip(pair_labels, corr_values)):
    ax.text(
        0, i,
        f"{val:.2f}",
        ha='center', va='center',
        fontsize=8
    )

plt.colorbar(im, label='Correlación absoluta')
plt.title(f'Top {top_k} pares de variables más correlacionados')
plt.tight_layout()
plt.show()

def calculate_correlation_with_target(df):
    num_cols = df.select_dtypes(include=['float64', 'int64']).columns
    num_cols = num_cols.drop('target') # exclude target

    # Serie con correlación de cada numérica contra target
    corr_with_target = df[num_cols].corrwith(df['target']).dropna()

    # Ordenar por valor absoluto (mayor importancia primero)
    order = corr_with_target.abs().sort_values(ascending=False).index
    corr_sorted = corr_with_target.loc[order]

    # Plot horizontal (mayores correlaciones arriba), coloreando por signo
    plt.figure(figsize=(6, max(6, len(corr_sorted) * 0.12)))
    colors = ['tab:red' if v > 0 else 'tab:blue' for v in corr_sorted.values]
    y = np.arange(len(corr_sorted))

    plt.barh(y, corr_sorted.values, color=colors)
    plt.yticks(y, corr_sorted.index, fontsize=8)
    plt.gca().invert_yaxis() # poner la mayor correlación arriba
    plt.xlabel('Correlación con target')
    plt.title("Correlación de 'target' con variables numéricas (ordenado por")
    plt.grid(axis='x', linestyle='--', alpha=0.4)
    plt.tight_layout()
    plt.show()

    strong_corr = corr_sorted.head(20)

    return strong_corr

```

```

def calculate_lift(df):
    num_cols = df.select_dtypes(include=['float64','int64']).columns
    num_cols = num_cols.drop('target') # exclude target

    aux = df[num_cols].groupby(df.target).mean().T
    aux['lift'] = aux[1] / aux[0]
    aux = aux.sort_values(by='lift', ascending=False)
    display(aux.head(20))
    display(aux.tail(20))

    top_lift = aux.head(20)['lift']
    bottom_lift = aux.tail(20)['lift']

    strong_lifts = pd.concat([top_lift, bottom_lift])

    return strong_lifts

def display_nan_percentage(df):
    nan_percentage = df.isna().mean() * 100
    nan_percentage = nan_percentage[nan_percentage > 0].sort_values(ascending=True)

    display(nan_percentage.head(10).to_frame(name='Top 10 % of NaN values'))
    display(nan_percentage.tail(10).to_frame(name='Bottom 10 % of NaN values'))

def plot_distributions(df, dtype):

    columns = df.select_dtypes(include=dtype).columns

    n = len(columns)
    ncols = 3
    nrows = math.ceil(n / ncols)

    fig, axes = plt.subplots(nrows=nrows, ncols=ncols, figsize=(ncols*5, nrows*3))
    axes = axes.flatten()

    if (isinstance(dtype, str) and dtype == 'object') or (isinstance(dtype, list) and '# categorical variables' in dtype):
        if len(columns) == 0:
            plt.close()
            return
        for i, col in enumerate(columns):
            counts = df[col].value_counts().sort_values(ascending=True).head(10)

            axes[i].barh(counts.index.astype(str), counts.values)
            axes[i].set_title(col)
            axes[i].tick_params(axis='x', rotation=45, pad=3)

        for j in range(i + 1, len(axes)):
            fig.delaxes(axes[j])
    else:
        for i, col in enumerate(columns):
            axes[i].hist(df[col].dropna(), bins=20)
            axes[i].axvline(df[col].mean(), color='red', linestyle='--')
            axes[i].set_title(col)

        for j in range(i + 1, len(axes)):

```

```
fig.delaxes(axes[j])

plt.tight_layout()
plt.show()

def data_snooping(df):
    display(Markdown(f"The dataset {df.Name} contains {df.shape[0]} observations"))

    display(Markdown("## Number of rows by target class:"))
    display(df.target.value_counts().to_frame())
    print()

    display(Markdown("## Number of columns by data type:"))
    display(df.dtypes.value_counts().to_frame())
    print()

    display(Markdown("## Percentage of NaN values per column:"))
    display_nan_percentage(df)
    print()

    display(Markdown("## Distribution of categorical variables:"))
    plot_distributions(df, dtype='object')
    print()

    display(Markdown("## Distribution of numerical variables:"))
    plot_distributions(df, dtype=['float64', 'int64'])
    print()

    display(Markdown("## Lift analysis of numerical variables:"))
    strong_lifts = calculate_lift(df)
    print()

    display(Markdown("## Correlation of numerical variables with target:"))
    print()
    strong_corr = calculate_correlation_with_target(df)
    candidate_features_df = pd.concat([strong_corr.to_frame(name='correlation'), df])
    candidate_features = list(candidate_features_df.index)

    display(Markdown("## Correlation between candidate features:"))
    calculate_correlation_between_features(df, candidate_features, top_k=30)
```

In [6]: `data_snooping(app)`

```
NameError Traceback (most recent call last)
Cell In[6], line 1
----> 1 data_snooping(app)

Cell In[5], line 163, in data_snooping(df)
  162 def data_snooping(df):
--> 163     display(Markdown(f"The dataset {df.Name} contains {df.shape[0]} observations and {df.shape[1]} columns.\n"))
  165     display(Markdown("## Number of rows by target class:"))
  166     display(df.target.value_counts().to_frame())

NameError: name 'Markdown' is not defined
```